

MILIS ÇOKLU ÖRNEKLE ÖĞRENME ALGORİTMASININ FARKLI BİR ÖRNEK SEÇME YÖNTEMİYLE YENİDEN İNCELENMESİ

REVISITING MILIS MULTIPLE INSTANCE LEARNING ALGORITHM WITH A DIFFERENT INSTANCE SELECTION MECHANISM

Osman Akın, Aykut Erdem, Erkut Erdem

Bilgisayar Mühendisliği Bölümü
Hacettepe Üniversitesi

oakin25@gmail.com, aykut@cs.hacettepe.edu.tr, erkut@cs.hacettepe.edu.tr

ÖZETÇE

Çoklu örnekle öğrenme (ÇÖÖ) (multiple instance learning), geleneksel tekil örnek sınıflandırmasından ziyade çoklu örneklerden oluşan torbaların sınıflandırılmasını esas alan yeni bir öğrenme paradigmasıdır. ÇÖÖ bağlamında bir torba sadece negatif örneklerden oluşuyor ise negatif olarak etiketlenirken; bir torbanın pozitif olarak etiketlenmesinin yolu torbanın en az bir pozitif örnek içermesidir. Bu öğrenme yaklaşımı, protein/metin/görüntü sınıflandırması ve nesne tanıma gibi özünde belirsizlik içeren bir çok örüntü tanıma ve bilgisayarla görme probleminin modellenmesi için doğal bir yapı oluşturmakta ve bu tür problemler için tekil örnekle öğrenme (TÖÖ) yöntemlerine kıyasla daha başarılı sonuçlar vermektedir. ÇÖÖ için önerilen genel yaklaşımlardan biri verilen bir ÇÖÖ problemini bir TÖÖ problemine dönüştürerek çözmektir. Bu dönüşüm temelde eğitime sırasında kullanılan torbalardan bazı belirli örneklerin seçimine dayanmaktadır. Bu grup çalışmalar arasındaki ana fark bu örnek seçme işlemi için farklı farklı yöntemler önermiş olmalarıdır. Bu çalışma kapsamında bu tarz bir ÇÖÖ yöntemi olan MILIS algoritması ele alınmış ve bu algoritma için farklı bir örnek seçme yöntemi önerilmiştir. Standart ÇÖÖ veri kümeleri üzerinde elde ettiğimiz sonuçlar bu yeni yöntemin aslından daha iyi sonuçlar verebildiğini göstermektedir.

ABSTRACT


Multiple instance learning (MIL) is a new paradigm in machine learning that deals with classification of bags of instances, as opposed to the traditional view that aims at learning from single instances. In a typical MIL setting, a negative bag is composed of only negative instances. On the other hand, a bag is considered positive if it contains at least one positive instance. This learning approach provides a natural way of modeling several pattern recognition and computer vision problems, e.g. protein, document and image classification and object recognition, which inherently require learning under ambiguity. In many cases, MIL approaches performs better than the standard single instance learning (SIL) methods. One of the general approaches to MIL is to transform a given MIL problem into a corresponding SIL problem. This transformation is mainly done with selecting a set of representative instances from the training bags, and these group of studies basically differ from each other on how they perform this instance selection step. In this study, we revisit such a MIL approach called MILIS with a different instance selection mechanism. The experimental results show that the proposed approach performs better on MIL benchmark data sets as compared to the original algorithm.

1. GİRİŞ

Tekil örnekle öğrenme (TÖÖ) olarak adlandırılabilen geleneksel gözetimli öğrenmede öğrenme, örnek/etiket ikilileri üzerinden yapılırken; amaç verilen yeni bir örneğin etiketinin en doğru biçimde tahmin edilmesidir (Şekil 1(a)). Ancak, özellikle doğası gereği belirsizlik içeren bazı öğrenme problemlerinde bu örnek/etiket eşleştirmesini yapmak ya çok zor ya da bazı durumlarda imkansızdır. Bu bağlamda, çoklu örnekle öğrenme (ÇÖÖ)[5], gözetimli öğrenme alanında önerilmiş yeni bir paradigma olarak örnekler yerine torba olarak adlandırılan örnek kümelerinin sınıflandırılmasını amaçlar. Diğer bir ifadeyle, ÇÖÖ’de öğrenme örnek/etiket ikilileri yerine torba/etiket ikilileri üzerinden gerçekleştirilmektedir (Şekil 1 (b)).

Tipik ÇÖÖ formülasyonunda bir torba sadece negatif örneklerden oluşuyor ise negatif, en az bir pozitif örnek içeriyor ise pozitif olarak etiketlenmektedir. Pozitif torbaların bu şekilde tanımlanması verideki belirsizliği işaret eder ve üstesinden gelinmeye çalışılan en önemli faktördür. Pozitif torbalardaki negatif örneklerin sayısında bir sınır olmaması, bu torbalardaki pozitif olan örneklerin ayıklanmasını ve öğrenmenin buna göre gerçekleştirilmesini zorlaştırır.

ÇÖÖ problemlerini çözmek için literatürde birçok yaklaşım önerilmiştir. Önerilen bu yaklaşımlar temel olarak üretici (generative) veya ayırt edici (discriminative) yaklaşımlar olarak iki grupta toplanabilir. Üretici yaklaşımda hedef kavram, örnek öznitelik uzayında tüm pozitif örnekleri kapsayan ama aynı zamanda negatif torbalardaki örneklerden olabildiğince uzak olan bir bölge ile temsil edilir. Dietterich, Lathrop ve Lozano-Perez [5], bu bölgeyi yüksek paralel eksenli dikdörtgenler kullanarak bulmaya çalışmışlardır. Maron ve Lozano-Perez [9] ise bu bölgeyi yüksek yoğunluklu



Şekil 1: Yapay öğrenme paradigmaları. (a) Geleneksel tekil örnekle öğrenme (b) Çoklu örnekle öğrenme.

(diverse density-DD) pozitif örneklerin temsil ettiğini ileri sürmüşlerdir. Bu yöntem EM-DD [11] ve GEM-DD [10] ile daha da geliştirilmiştir. İkinci tür yaklaşımı temsil eden ayırt edici ÇÖÖ yaklaşımları ise klasik gözetimli öğrenme yöntemlerini ÇÖÖ ortamına uyarlamayı hedefler. Bu gruptaki metodlardan başlıcaları MI-SVM, miSVM[1], DD-SVM[3]'dir.

Belli bir grup ayırt edici algoritma, verilen bir ÇÖÖ problemini karşılık gelen bir TÖÖ problemine dönüştürerek çözmeye çalışır (Şekil 2). Bu grup yöntemlere DD-SVM[3], MILES[4], MILD[8], MILIS[7] ve MILDS[6]'i örnek verebiliriz. Bu algoritmaların izlediği genel yol, eğitim esnasında torbalardan bazı belirleyici örnekler seçmek ve seçilen bu örnek kümesini kullanarak torba seviyesinde bir gömülme uzayı (embedding space) oluşturmaktır. Bu yöntemleri birbirinden ayıran en önemli nokta, bu belirleyici örneklerin nasıl seçildiğidir. Bu seçme işleminin ardından her torba bir gömülme uzayına taşınabildiğinden bu uzayda TÖÖ'ye dayalı standart sınıflandırıcılar eğitmek mümkün olmaktadır.

DD-SVM[3], bu örnek seçimini yüksek yoğunluk fonksiyonuna dayalı olarak gerçekleştirirken MILES[4]'da ise örnek seçimi açıkça yapılmaz. Onun yerine yazarlar, torba seviyesindeki gömülme uzayını, bir torbanın eğitim torbalarındaki bütün örneklerle olan uzaklığına göre oluşturmuşlardır. Burada örnek seçimi, destek vektör makinelerinin (DVM) (support vector machines) eğitimi aşamasına kaydırılmış ve oluşturulan çok yüksek boyutlu gömülme uzayı üzerinde örtülü olarak yapılmaktadır. MILIS[7], MILD[8], MILDS[6]'de ise pozitif ve negatif torbalardan belirleyici örnekleri daha doğru seçmek için daha etkin yollar önerilmiştir. MILIS[7], negatif örnek sınıfını eğitim aşamasındaki negatif torbalardaki örneklerden çekirdek yoğunluk kestirimi (ÇYK) (kernel density estimation – KDE) kullanarak modellemeyi ve örnek seçimini buna göre gerçekleştirmeyi önermiştir. MILD[8]'de ise önerilen örnek seçimi Bayesçi bir yöntemle dayanmaktadır. MILDS[6]'de ise belirleyici örneklerin seçimi öbeklemeye dayalı bir yaklaşım kullanarak gerçekleştirilmektedir.


Bu çalışmada MILIS yöntemi farklı bir örnek seçme stratejisi ile yeniden ele alınmıştır. Burada amaçlanan yine ÇYK'ye dayanan ancak negatif torbalardan seçilen örneklerin daha belirleyici olduğu bir seçim gerçekleştirmektir. Makalenin geri kalanı şu şekilde düzenlenmiştir: Bölüm 2'de MILIS'in orijinal örnek seçme stratejisi ve ilgili ÇÖÖ yöntemi özetlenmiştir. Bölüm 3'de MILIS'in örnek seçme stratejisine alternatif olarak önerilen yeni seçme stratejisi anlatılmaktadır. Bölüm 4'de ise standart veri kümeleri üzerinde yapılan deneylerin sonuçları verilmiştir.

2. MILIS ALGORİTMASINA GENEL BAKIŞ

Makalede kullanılan matematiksel gösterimler şu şekildedir:

- $B_i = \{x_{i1}, \dots, x_{ij}, \dots, x_{im_i}\}$: i 'ninci örnek torbası,
- x_{ij} : i 'ninci torbadaki j 'ninci örnek,
- $y_i \in \{+1, -1\}$: i 'ninci torbanın etiketi,
- B^+ : pozitif torba,
- B^- : negatif torba,
- $\mathcal{B} = \{B_1^+, \dots, B_{m^+}^+, B_1^-, \dots, B_{m^-}^-\}$: m^+ sayıdaki pozitif ve m^- sayıdaki negatif torbadan oluşan eğitim kümesi.

Burada dikkat çekmek gerekir ki her torba farklı sayıda örnek içerebilmektedir.



Şekil 2: Bir ÇÖÖ probleminin belirleyici örnek seçimine dayalı olarak ilgili bir TÖÖ problemine dönüştürülmesi.

MILIS yöntemi belirleyici örnek seçimi ve sınıflandırıcı eğitimi olarak iki aşamadan oluşur. Birinci aşama, eğitim kümesindeki her negatif torbadan en negatif örneğin ve her pozitif torbadan da en az negatif (yani, en yüksek pozitif) örneğin seçilmesini amaçlamaktadır. Tanım gereği bir negatif torbadaki bütün örnekler negatif kabul edildiği için MILIS, negatif sınıfı negatif torbalardaki tüm örnekler üzerinden ÇYK'ne dayalı olarak modellemeyi önermiştir:

$$f(x) = \frac{1}{Z \sum_{i=1}^{m^-} m_i^-} \sum_{i=1}^{m^-} \sum_{j=1}^{m_i^-} \exp(-\beta \|x - x_{ij}^-\|) \quad (1)$$

(Z : normalizasyon faktörü, β : ölçek parametresi)

Böylece negatif bir torbadan seçilen belirleyici örnek, bu modele göre negatif sınıfa ait olma olasılığı en yüksek olan örneğe (en negatif örnek) karşılık gelmektedir:

$$x_i^- = \arg \max_{x_{ij} \in B_i^-} f(x_{ij}) \quad (2)$$

Diğer yandan tanım gereği pozitif torbalar hem negatif hem de pozitif örnekler içerebildiği için burada en belirleyici pozitif örneği bulmak zordur. Burada MILIS'in tercih ettiği yol, en doğru pozitif örneği yine öğrenilen olasılıksal modelden faydalanarak belirlemektir. Pozitif bir torbadan seçilen örnek, öğrenilen modele göre negatif sınıfa ait olma olasılığı en düşük olan örneğe (yani en yüksek pozitif örneğe) karşılık gelmektedir:

$$x_i^+ = \arg \min_{x_{ij} \in B_i^+} f(x_{ij}) \quad (3)$$


Negatif ve pozitif torbalardan yukarıda anlatılan şekilde belirleyici örnekler seçildikten sonra bu örnek kümesi ÇÖÖ problemini ilgili bir TÖÖ problemine dönüştürmek amacıyla benzerliğe dayalı bir gömülme uzayı oluşturmada kullanılır. Bunun için bir torbanın belirleyici bir örneğe olan uzaklığını hesaplayan bir fonksiyona ihtiyaç vardır. MILIS, bu amaçla aşağıda tanımlanan Hausdorff uzaklığını kullanmayı önermiştir (Şekil 3):

$$d(B_i, x) = \min_{x_{ij} \in B_i} \|x_{ij} - x\|^2 \quad (4)$$

Bu uzaklığa dayanan torba düzeyinde bir gömülme fonksiyonu, verilen bir torbanın seçilmiş olan örneklerle olan benzerlikleri üzerinden aşağıdaki şekilde tanımlanabilir:

$$g(B) = [s(B, x_1^-), \dots, s(B, x_{m^-}^-), s(B, x_1^+), \dots, s(B, x_{m^+}^+)] \quad (5)$$

$$s(B, x) = \exp(-\beta d(B, x)) \quad (6)$$



Şekil 3: Bir torbanın bir belirleyici örneğe olan uzaklığının Hausdorff uzaklığına dayalı gösterimi.

Bu gömülme fonksiyonu sayesinde ÇÖÖ problemi ilgili bir TÖÖ problemine indirgenebilmekte ve bu gömülme uzayında standart bir sınıflandırıcı eğitilebilmektedir. MILIS algoritması, hesaplama avantajı ve doğrusal olmayan veri ayrıştırmadaki başarısından dolayı sınıflandırıcı olarak L_2 -norm doğrusal DVM kullanmıştır. Her ne kadar bu çalışma kapsamında incelenmemiş olsa da MILIS yöntemi sınıflandırma başarısı arttırmak için seçilen belirleyici örnek kümesi üzerinde bir güncelleme işlemi de önermiştir.

3. med-MILIS ALGORİTMASI

Bu bölümde *med-MILIS* olarak adlandırılan MILIS algoritmasının bir varyasyonu önerilmektedir. Bir önceki bölümde özetlendiği üzere MILIS, eğitim sırasında sağlanan torbalardan belirleyici örnek seçiminde ÇYK tabanlı bir model kullanmaktadır. Gömülmeyi oluşturmak için kullanılan negatif örnekler, negatif eğitim torbalarındaki en negatif örnekler olarak belirlenmektedir (Denklem 2). Bu varsayım yanlış olmamakla beraber, özellikle çok biçimli (multimodal) dağılımlar için çoğunlukla baskın modlara yakın örneklerin seçilmesiyle sonuçlanabilir ve bu da gerçek dağılımın eksik bir biçimde temsil edilmesi sonucunu doğurabilir.

Bu çalışmada bu yukarıda değinilen olumsuz durumu ortadan kaldırmak ve daha doğru bir gömülme yaratmak adına negatif torbalardan örnek seçerken en negatif örneği almak yerine negatif sınıfa ait olma olasılık değerleri sıralandığında %50'ninci sırada yer alan (medyan) örneği almak önerilmiştir. Yani, ÇYK modeline göre bir negatif torbadaki en belirleyici örnek şu şekilde tanımlanmıştır:

$$\tilde{x}_i^- = \arg \max_{x_{ij} \in B_i^-} f(x_{ij}) \quad (7)$$

($\arg \max_{x_{ij} \in B_i^-} f(x_{ij})$: f değeri kümesindeki değerler küçükten büyüğe sıralandığında %50'inci değeri)

Yukarıda değinilen ortaya çıkabilecek olumsuzluk MILIS'de sadece seçilen negatif örnekler için geçerli olduğundan pozitif torbalardan belirleyici örnek seçiminde bir değişikliğe gidilmemiş, bu amaçla yine Denklem 3 kullanılmıştır.

Yeni önerilen bu örnek seçme yönteminin orijinaline göre avantajını göstermek adına Şekil 4(a)'da gösterilen sentetik olarak yaratılmış iki boyutlu veri kümesini ele alalım. Bu basit veri kümesi, herbiri 8 ila 10 örnek içeren 8 pozitif ve 8 negatif torbadan oluşmakta ve torbalardaki örnekler şu beş Gauss dağılımının birinden gelmektedir: $N([4,8]^T, I)$, $N([0,4]^T, I)$, $N([-1,12]^T, I)$, $N([-4,-2]^T, I)$ ve $N([6,2]^T, I)$ (I : birim matris). Eğer bir torba ilk iki dağılımın birinden gelen en az

bir örnek içeriyorsa pozitif, öbür durumda ise negatif olarak etiketlenmiştir. Buna göre Şekil 4(a)'da pozitif ve negatif örnekler sırasıyla 'x' ve 'o' sembolleriyle işaretlenmiştir. Buna ek olarak pozitif torbalardaki örnekler kırmızı, negatif torbalardakiler ise mavi renkle çizilmiştir. Bu veri kümesi üzerinde MILIS'in seçtiği örnekler Şekil 4(b)'de, önerilen *med-MILIS* yönteminin seçme sonucu ise Şekil 4(c)'de gösterilmektedir. Görülebileceği üzere MILIS algoritması, negatif belirleyici örnekleri baskın bir çoğunlukla dördüncü dağılımdan (baskın mod) seçerken, *med-MILIS* ise örnek seçimini negatif sınıfı tanımlayan tüm dağılımlardan daha dengeli bir şekilde gerçekleştirmiştir.

Belirleyici örnekler yukarıda anlatıldığı gibi seçildikten sonra orijinal formülasyonda olduğu gibi torba düzeyinde tanımlanan bir gömülme fonksiyonu şu şekilde verilebilir:

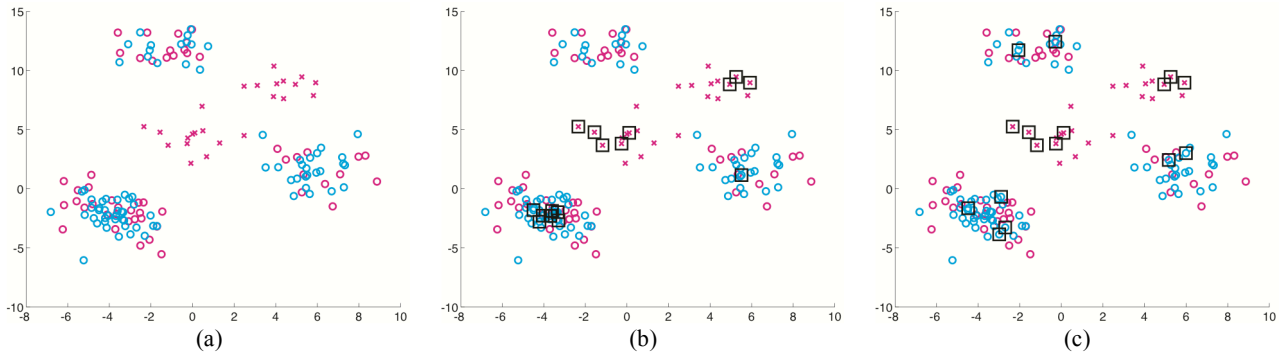
$$g'(B) = [s(B, \tilde{x}_1^-), \dots, s(B, \tilde{x}_m^-), s(B, x_1^+), \dots, s(B, x_m^+)] \quad (9)$$

Bunun ardından Bölüm 2'de anlatıldığı gibi ÇÖÖ problemi ilgili bir TÖÖ problemine indirgenerek, bu gömülme uzayında yine bir L_2 -norm doğrusal DVM eğitmek yoluyla çözülebilir.


4. DENEY SONUÇLARI

Bu çalışmada önerilen örnek seçme yönteminin sınıflandırma başarısı üzerindeki etkisini ölçmek için literatürde çokça kullanılan beş ÇÖÖ veri kümesinden (*Musk1*, *Musk2* [5] ve *Elephant*, *Tiger*, *Fox* [1]) faydalanılmıştır. *Musk1* ve *Musk2* veri kümelerindeki amaç, ilaç etkinliğinin yapısal bilgiye dayalı öğrenilmesidir. Bu iki veri kümesinde her torba bir ilaç molekülüne karşılık gelirken; torbalar ilgili molekülün farklı yapısal hallerini temsil eden örnekleri içermektedir (Şekil 5). *Elephant*, *Fox* ve *Tiger* veri kümelerinde ise verilen bir görüntünün herhangi bir nesne sınıfından (fil, tilki ve kaplan) bir örneği içerip içermediği tahmin edilmeye çalışılır. Burada ise her görüntü bir torbaya karşılık gelirken; torbadaki örnekler de görüntü üzerinde bir bölütleme algoritması çalıştırılarak elde edilen alanlara karşılık gelmektedir (Şekil 6). Deneylerde kullanılan bu veri kümeleri ile ilgili detaylar Tablo 1'de özetlenmiştir.


Gerçekleştirilen deneylerde orijinal ve yeni önerilen örnek seçme yöntemlerince oluşturulan gömülme uzaylarında DVM eğitimi için LIBSVM [2] paketi kullanılmıştır. MILIS algoritması ve önerilen eklentiye sahip hali toplamda iki parametreye sahiptir: DVM düzgünleştirme parametresi C 'ye ek olarak bir de ölçek parametresi β vardır. Her bir deney için bu iki parametrenin en iyi değerleri her yöntem için $\{2^{-10}, 2^{-9},$



Şekil 4: Belirleyici örneklerin seçimi (a) Sentetik veri kümesi. (b) MILIS yönteminin seçme sonucu (c) *med-MILIS* yönteminin seçme sonucu. Torbalardan seçilen örnekler kare içine alınmıştır.



Şekil 5: (a) Musk moleküllerinden örnekler (b) Moleküllerin çokbüçümlülüğüne dair bir örnek ([1]'den alınmıştır).



Şekil 6: Elephant ve Tiger veri kümelerinde bulunan görüntülerden bazı örnekler ([6]'dan alınmıştır).

..., 2^{10} ve $\mu \times \{0.05, 0.10, \dots, 0.95, 1.00\}$ (μ : eğitim kümesindeki örnekler arasındaki ortalama uzaklık) değer kümeleri üzerinden 5-kat çapraz onaylama (5-fold cross-validation) kullanılarak belirlenmiştir.

Elde edilen sınıflandırma başarı değerleri Tablo 2'de verilmiştir. Bu deneysel analiz için ÇÖÖ algoritmaların test edilmesinde standart olarak kullanılan 10 defa 10-kat çapraz onaylama kullanılmıştır. Yani rapor edilen değerler her birinde 10-kat çapraz onaylamanın kullanıldığı 10 çalışma üzerinden alınan ortalama sınıflandırma başarılarını göstermektedir. Bu elde ettiğimiz sonuçlar, bu çalışmada önerilen med-MILIS yönteminin orjinal MILIS yöntemine kıyasla çok daha iyi sonuçlar verebildiğini göstermektedir. Bu medyan hesabına dayalı belirleyici örnek seçiminin daha başarılı bir gömülü uzay yarattığını işaret etmektedir.

5. SONUÇLAR

Bu makalede MILIS çoklu örnekle öğrenme algoritması yeni bir örnek seçme stratejisi ile yeniden ele alınmıştır. Önerilen yeni strateji negatif torbalardan en negatif örneği almak yerine medyan örneği almak üzerine kurulmuştur. Bu yeni strateji orjinaline kıyasla negatif sınıfı daha doğru temsil eden belirleyici örnekler seçmeye olanak sağlamaktadır. Standart ÇÖÖ veri kümeleri üzerinde gerçekleştirilen deneyler bu yeni yöntemin orjinaline göre daha başarılı sonuçlar verdiğini ortaya koymaktadır. Elde edilen sonuçlar örnek seçmenin sınıflandırıcı başarısındaki önemini göstermekte ve bu konunun üzerinde daha çok çalışılması gerektiğini işaret etmektedir. Son olarak belirtmek isteriz ki bu çalışmada sınıflandırıcı eğitimi sırasında orjinal MILIS makalesinde önerilen örnek kümesi güncelleme işlemi dışarıda bırakılmış ve ilk seçilen örnek kümesi her iki yöntem için de sabit tutulmuştur. Önerilen belirleyici örnek seçme yönteminin bu güncelleme işlemiyle birleştirildiğindeki başarısı daha sonra incelenecektir. Güncelleme işlemi, ilk seçilen kümeyle direkt bağlı olduğundan bu durumda da orjinal yöntemle oranla daha iyi sonuçlar elde edilebileceği düşünülmektedir.

Tablo 1: Deneylerde kullanılan ÇÖÖ veri kümeleri

Veri kümesi	Torba sayıları (pozitif/negatif)	Ortalama torba büyüklüğü	Öznitelik boyutu
Musk1	47/45	5.17	166
Musk2	39/63	64.69	166
Elephant	100/100	6.96	230
Fox	100/100	6.60	230
Tiger	100/100	6.10	230

Tablo 2: Sınıflandırma Sonuçları

Veri kümesi	Algoritma	
	MILIS	med-MILIS
Musk1	83.5	86.9
Musk2	89.4	89.4
Fox	61.5	63.0
Elephant	83.8	84.2
Tiger	79.9	82.0

6. KAYNAKÇA

- [1] Andrews, S., Tsochantaridis, I., and Hofmann, T., "Support Vector Machines for Multiple-Instance Learning", Proc. Conf. Advances in Neural Information Processing Systems, pp. 561-568, 2003.
- [2] Chang, C.C., Lin, C.J., "LIBSVM: A library for support vector machines", 2001, software, <http://www.csie.ntu.edu.tw/~cjlin/libsvm>
- [3] Chen, Y., Wang, J.Z., "Image Categorization by Learning and Reasoning with Regions", J. Machine Learning Research, vol. 5, pp. 913-939, 2004.
- [4] Chen, Y., Bi, J., and Wang, J., "MILES: Multiple-Instance Learning via Embedded Instance Selection," IEEE Trans. Pattern Anal. Mach. Intell. 28(12), pp. 1931-1947, 2006.
- [5] Dietterich, T.G., Lathrop, R.H., and Lozano-Perez, T., "Solving the Multiple-Instance Problem with Axis-Parallel Rectangles", Artif. Intell. 89(1-2), pp. 31-71, 1997.
- [6] Erdem, A., Erdem, E., "Multiple-Instance Learning with Instance Selection via Dominant Sets", 1st Int. Workshop on Similarity-Based Pattern Analysis and Recognition, Venice, Italy, Springer LNCS, Vol. 7005, pp. 177-191, 2011
- [7] Fu, Z., Robles-Kelly, A., and Zhou, J., "MILIS: Multiple Instance Learning with Instance Selection", IEEE Trans. Pattern Anal. Mach. Intell. 33(5), pp. 958-977, 2011.
- [8] Li, W.J., Yeung, D.Y., "MILD: Multiple-instance learning via disambiguation", IEEE Trans. Knowl. and Data Eng. (22), pp. 76-89, 2010.
- [9] Maron, O., and Lozano-Perez, T., "A Framework for Multiple-Instance Learning" Proc. Conf. Advances in Neural Information Processing Systems, pp. 570-576, 1998.
- [10] Rahmani, R., Goldman, S.A., Zhang, H., Cholleti, S.R., and Fritts, J.E., "Localized Content Based Image Retrieval," IEEE Trans. Pattern Anal. Mach. Intell. 30(11), pp. 1902-2002, 2008.
- [11] Zhang, Q., Goldman, S. "EM-DD: An Improved Multiple-Instance Learning Technique," Proc. Conf. Advances in Neural Information Processing Systems, pp. 561-568, 2002.